并行程序设计-字符串匹配

宋安邦 卢康 罗志豪 王昌家

目　录

1

功　能　描　述

字符串匹配问题

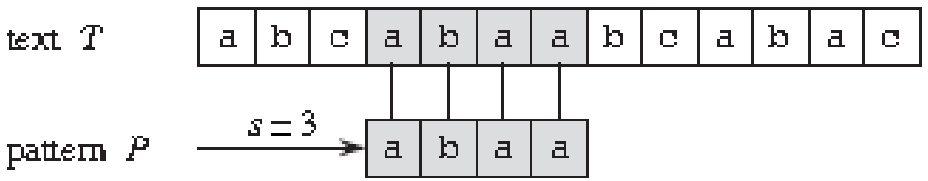

文本（Text）是一个长度为 m 的数组 T[1..m]；

模式（Pattern）是一个长度为 n 且 n≤m 的数组 P[1..n]；

字符串匹配问题是指在一个较大的字符串（称为文本）中查找一个较小的字符串（称为模式）是否出现，以及确定模式出现的位置或者出现的次数。

2

单 线 程 算 法

常用的字符串匹配算法

朴素算法（Naive Algorithm）

该算法的基本思想是从主串 T 的第一个字符开始和模式串 P 的第一个字符进行比较，若相等，则继续比较二者的后续字符；否则，模式串 P 回退到第一个字符，重新和主串 T 的第二个字符进行比较。如此往复，直到 T 或 P 中所有字符比较完毕。

Knuth-Morris-Pratt 算法（KMP Algorithm）

KMP算法的思想是，当子串与模式串 P 不匹配时，其实已经知道了前面已经匹配成功那一部分的字符（包括子串与模式串），因此可以确定下一步从哪里开始，从而避免重新检查先前匹配的字符。

算法分为两个部分，第一部分是在预处理阶段处理模式串 P，构建 next 数组，复杂度为 O(n)，其中 n 是模式串的长度；第二部分就是匹配过程了，复杂度是 O(m)，其中 m 是文本串的长度。

KMP (Knuth-Morris-Pratt)

```cpp
static void build_prefix_suffix_array(const char* pattern, size_t pattern_len, int* pps) {
    int length = 0;
    pps[0] = 0;
    size_t i = 1;
    while (i < pattern_len) {
        if (pattern[i] == pattern[length]) {
            length++;
            pps[i] = length;
            i++;
        }
        else {
            if (length != 0)
                length = pps[length - 1];
            else {
                pps[i] = 0;
                i++;
            }
        }
    }
}
```

```cpp
auto kmp_search(const char* text, const size_t text_len, const char* pattern, const size_t pattern_len) -> std::vector<size_t> {
    // 部分匹配表 (Partial Match Table) ，也称为前缀后缀表 (Prefix-Suffix Table) 。
    int pps[pattern_len];
    build_prefix_suffix_array(pattern, pattern_len, pps);

    std::vector<size_t> result;
    // i用于遍历文本，j用于遍历模式串。
    int i = 0;
    int j = 0;
    while (i < text_len) {
        // 如果当前字符匹配成功，则模式串和文本都向后移动一个字符。
        if (pattern[j] == text[i]) {
            j++;
            i++;
        }
        // 完整匹配，将当前匹配的起始索引加入结果。
        if (j == pattern_len) {
            result.push_back(i - j);
            // 根据部分匹配表调整模式串指针j。
            j = pps[j - 1];
        }
        // 如果字符不匹配，并且i没有到达文本尾部。
        else if (i < text_len && pattern[j] != text[i]) {
            // j不为0时根据部分匹配表回溯。
            // 不是从模式串的开始位置重新匹配，j回到有最大前缀后缀匹配长度的位置。
            if (j != 0)
                j = pps[j - 1];
                // j为0时，则移动文本指针i。
            else
                i = i + 1;
        }
    }
    return result;
}

```

SIMD-based 搜索

假设我们有一些 8-byte 的寄存器，我们要在字符串“a_cat_tries”中搜索子串“cat”。首先我们将“cat”的第一个字节和最后一个字节填充到两个寄存器中，并尽可能地重复知道寄存器被填满。

F = [c | c | c | c | c | c | c | c]

L = [t | t | t | t | t | t | t | t]

然后我们将字符串“a_cat_tries”加载到另外两个寄存器中，其中一个寄存器从第二个字符开始加载。

A = [a | _ | c | a | t | _ | t | r]

B = [c | a | t | _ | t | r | i | e]

然后比较两组寄存器的内容，对应位置的内容相同为 1，反之则为 0。

AF = (A == F) = [0 | 0 | 1 | 0 | 0 | 0 | 0 | 0]

BL = (B == L) = [0 | 0 | 1 | 0 | 1 | 0 | 0 | 0]

最后我们将两个寄存器的内容合并，即 “位与” 运算。

mask = [0 | 0 | 1 | 0 | 0 | 0 | 0 | 0]

此时我们发现只有第 2 位（从零开始）是 1，这说明只有从此处开始搜索才有可能搜索到子串。这就减少了我们的搜索次数。

SIMD-based

```cpp
auto simd_search(const char* text, const size_t text_len, const char* pattern, const size_t pattern_len) ->
std::vector<size_t> {
    std::vector<size_t> result;

    // 向寄存器中填充 needle 的第一个字节
    const __m256i first = _mm256_set1_epi8(pattern[0]);
    // 向寄存器中填充 needle 的最后一个字节
    const __m256i last  = _mm256_set1_epi8(pattern[pattern_len - 1]);

    for (size_t i = 0; i < text_len; i += 32) {

        // 向寄存器中填充 s 的部分内容
        const __m256i block_first = _mm256_loadu_si256(reinterpret_cast<const __m256i*>(text + i));

        // 向寄存器中填充 s 的部分内容，相对于上一行，本次填充的内容有所偏移
        const __m256i block_last  = _mm256_loadu_si256(reinterpret_cast<const __m256i*>(text + i + pattern_len - 1));

        // 比较两组寄存器
        const __m256i eq_first = _mm256_cmpeq_epi8(first, block_first);
        const __m256i eq_last  = _mm256_cmpeq_epi8(last, block_last);

        // 合并两个寄存器的比较结果
        uint32_t mask = _mm256_movemask_epi8(_mm256_and_si256(eq_first, eq_last));

        while (mask != 0) {
            // 找到第一个值为 1 的 bit 的下标
            const auto bitpos = bits::get_first_bit_set(mask);

            if (memcmp(text + i + bitpos + 1, pattern + 1, pattern_len - 2) == 0) {
                result.push_back(i + bitpos);
            }

            mask = bits::clear_leftmost_set(mask);
        }
    }

    return result;
}
```

3 多 线 程 算 法

数据分配

```
struct Task {
    size_t  offset;
    size_t  size;

    Task() = default;
    Task(size_t offset, size_t size): offset(offset), size(size) {}
};
```

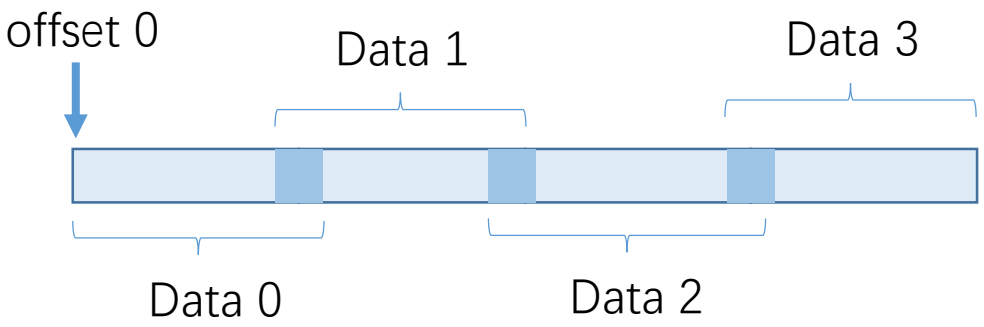

对于并行的字符串匹配，我们在启动线程前将空间分解为多个块（Data），并计算其起始偏移量和数据长度。

对于非第一个空间数据分配，它们的起始偏移量要向前一点点（pattern_len − 1），以保证搜索过程中不会有遗漏。

并行算法-伪代码（*KMP + OpenMP*）

```
auto base_addr = 内存起始地址;
auto file_len = 内存大小;
auto pattern_len = 模式串大小;

foreach task do
    // 按照线程数分配数据大小
    auto start = i == 0 ? 0 : (i * task_size - (pattern_len - 1));     // 获取每份数据的起始地址
    // 获取每份数据的真实大小
    auto real_size = i == threads - 1 ? min(task_size, file_len - i * task_size) : task_size;
    real_size += pattern_len;

    append Task(start, real_size);


parallel do
    auto index = 线程ID;
    auto task = 数据ID;
    auto result = kmp_search();
    // 计算当前模式串真正的偏移量
    for (auto &r: result) { r += _offset;}
    // 记录当前线程的查找结果
    mid_result[index] = result;
```

时间复杂度

OpenMP + KMP 算法的实现中，

1. 每个线程均需要对模式串生成 $next$ 数组，这部分时间复杂度为 $O(n)$。其中， n 为模式串长度。
2. KMP 算法的搜索过程中，由于我们将数据分解，这部分时间复杂度为 $O(m/p)$。其中，m 为文本长度，p 为线程数。

由于 $m/p >> n$，因此总的时间复杂度为 $O(m/p)$。

数据分配

```
// Generate tasks.
// Assume that total size is 395, we split it into 4 tasks. And the length to the pattern is 5.
//  |__100__|__100__|__100__|__95__|
// tasks are: [0, 100), [96, 200), [196, 300), [296, 395]
auto base_addr = p;
auto file_len = total_length;
auto pattern_len = strlen(pattern);
std::generate(tasks.begin(), tasks.end(), [&, i = 0]() mutable {
    auto start = i == 0 ? 0 : (i * task_size - (pattern_len - 1));
    auto real_size = i == threads - 1 ? std::min(task_size, file_len - i * task_size) : task_size;
    real_size += pattern_len;
    i++;
    return Task(start, real_size);
});
```

并行程序（*KMP + OpenMP*）

```
    // Assign tasks to threads.
#pragma omp parallel num_threads(threads)
    {
        auto index = omp_get_thread_num();
        auto task = tasks[index];

        auto [_offset, _size] = task;
        auto result = kmp_search(reinterpret_cast<const char *>(base_addr + task.offset), _size, pattern, strlen(pattern));

        // kmp_search only returns the offset to the pattern from the start of the block, not the base address.
        for (auto &r: result) {
            r += _offset;
        }
        mid_result[index] = std::move(result);
    }

    auto end = std::chrono::high_resolution_clock::now();
    auto duration = std::chrono::duration_cast<std::chrono::microseconds>(end - start).count();
    std::cout << "task finished, costs " << std::dec << duration << " microseconds (" << display_time(duration) << ")" << std::endl;

    auto result = std::vector<size_t>();
    for (auto &r: mid_result) {
        result.insert(result.end(), r.begin(), r.end());
    }

    return {result, duration};
}
```

此处，kmp_search 函数所返回的子串偏移量是相对于该任务的起始位置的，因此我们需要将结果换算成相对于整个查找区域的偏移量。

4 实 验 设 计

实验思路

1. 初始化：分配内存大小，并指定要搜索的字符串 PATTERN；
2. 在内存区域中随机放置模式字符串 PATTERN；
3. 使用单线程查找算法（KMP，SIMD-based search），并计时；
4. 使用基于 OpenMP 的改进算法，测试不同并行度下的用时；
5. 检查搜索结果，输出运行时间和加速比。

整体流程

```
int main() {
    const auto MIN_MEMORY_USE = 128 * 1024 * 1024L;
    const auto MAX_MEMORY_USE = 1 * 1024 * 1024 * 1024L;
    const auto PATTERN = "PATTERN";

    // 一次分配，多次使用，提高测试性能.
    auto p = new uint8_t[MAX_MEMORY_USE];
    memset(p, 0, MAX_MEMORY_USE); // 设置内存内容为 0

    // 内存大小
    for (auto size = MIN_MEMORY_USE; size <= MAX_MEMORY_USE; size *= 2) {

        generate_test_data(p, size, PATTERN, 5);
        auto durations = do_serial_test_in_memory(p, size, PATTERN);

        std::cout << "memory size: " << display_size(size)  << ", serial & SIMD costs: ";
        for (auto duration: durations) {
            std::cout << display_time(duration) << ", ";
        }
        std::cout << ", parallel costs:";

        // 线程数
        for (auto cores = 2; cores <= 4; cores *= 2) {
            auto durations_with_threads = do_parallel_test_in_memory(p, size, PATTERN, cores);
            for (auto duration: durations) {
                std::cout << "c" << cores << ": " << display_time(duration) << ", ";
            }
            std::cout << std::endl;
        }
    }

    delete[] p;
    return 0;
}
```

测试数据的产生方法

我们希望尽量均匀地在存储空间中放置测试数据。不妨将可用内存分为若干块（block），在每个块中放置一个模式串。该方式可以加速测试数据的生成，并不影响其分布特征。

```
auto generate_test_data(uint8_t* base, size_t size, const char *pattern, size_t count) -> void {
    memclr(base, size);

    auto pattern_len = strlen(pattern);
    std::random_device rd;  // 生成随机数
    std::mt19937 gen(rd()); // 伪随机数产生器
    // Designing a perfect placement algorithm can be complex. Here, we will simply evenly distribute the PATTERN
    // throughout the memory region.
    auto positions = std::vector<size_t>(count);
    auto block_size = size / count;
    std::uniform_int_distribution<int> dis(0, block_size - pattern_len);  // 产生字符串，类型为 int
    std::generate(positions.begin(), positions.end(), [&, i = 0, step = block_size]() mutable {
        return i++ * step + dis(gen);
    });

    auto i = 0;
    for (auto pos: positions) {
        auto _addr = base + pos;
        if (i++ < 4) {
            std::cout << "place pattern at 0x" << std::hex << reinterpret_cast<std::uintptr_t>(_addr) << std::endl;
        }
        memcpy(_addr, pattern, pattern_len);
    }

    auto flag = check_result_quickly(base, size, pattern, positions);
    if (!flag) {
        throw std::runtime_error("failed to place pattern in memory.");
    }
}
```

5 实 验 结 果

实验结果 单线程

数据集大小	串行	SIMD	加速比
128M	187ms938us	8ms346us	2252%
256M	370ms955us	10ms702us	3466%
512M	736ms102us	21ms338us	3450%
1G	1s470ms319us	42ms710us	3443%
2G	2s940ms240us	87ms14us	3379%

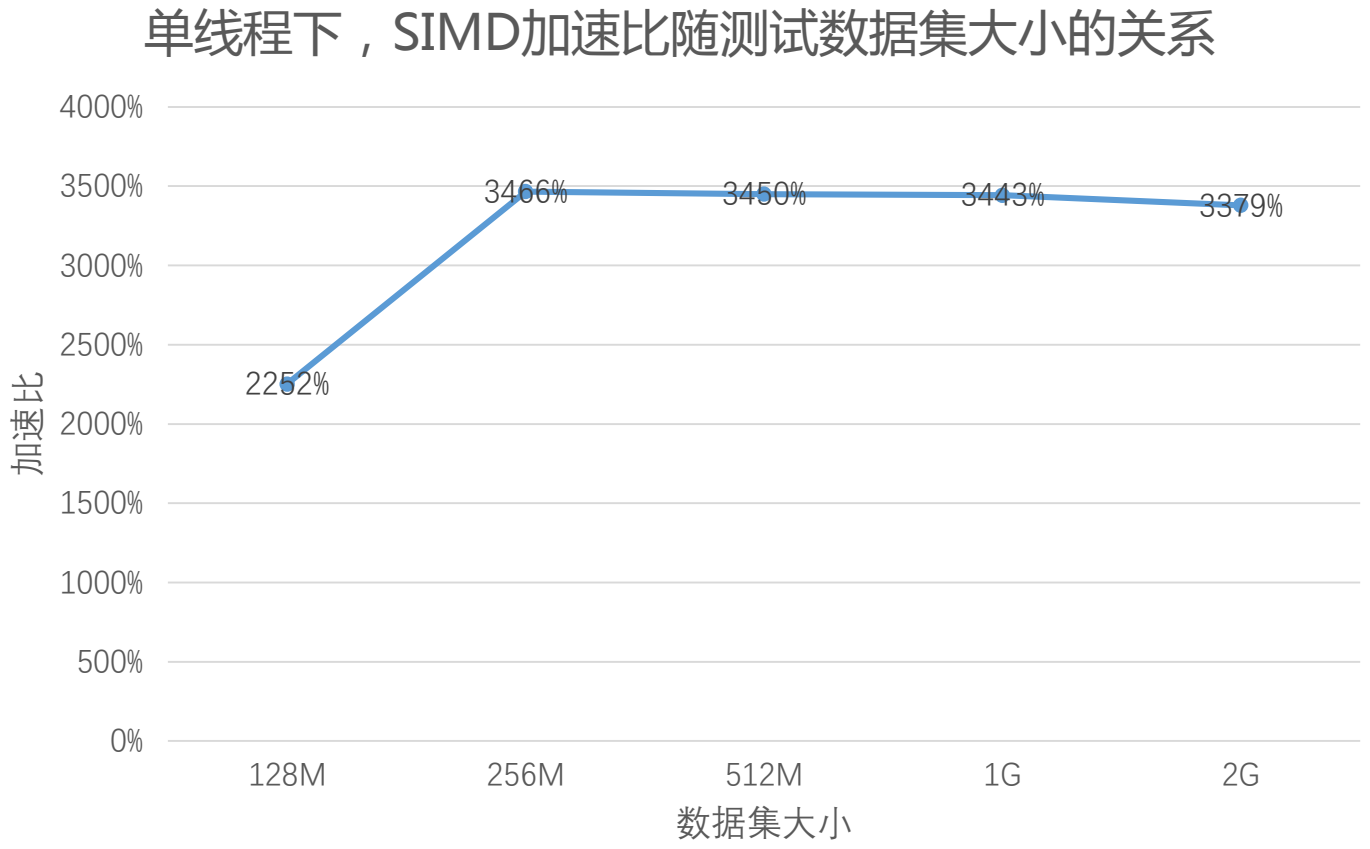

实验结果 多线程

数据集大小	OpenMP	OpenMP + SIMD	线程数
128M	97ms659us (192%)	3ms435us (5471%)	2
256M	189ms695us (196%)	6ms719us (5521%)	2
512M	382ms112us (193%)	13ms492us (5456%)	2
1G	756ms714us (194%)	27ms307us (5384%)	2
2G	1s511ms744us (194%)	54ms888us (5357%)	2

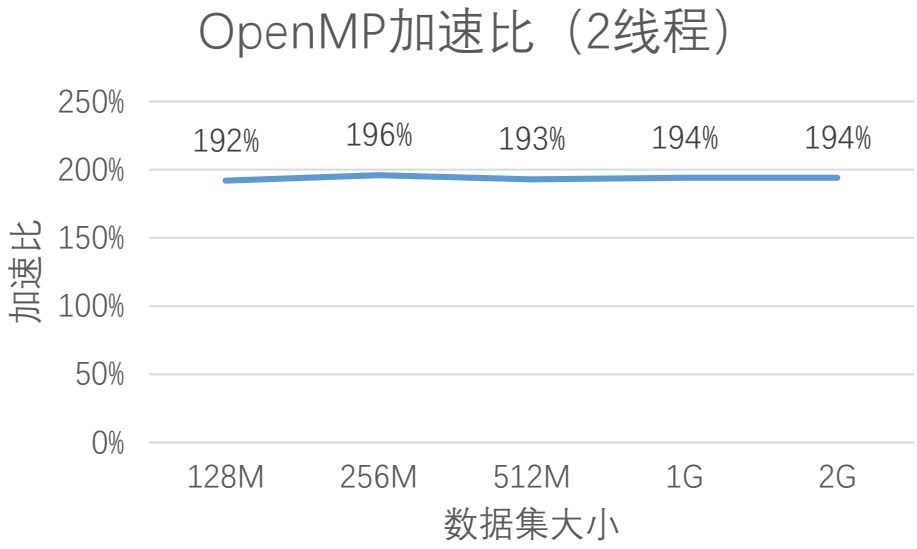

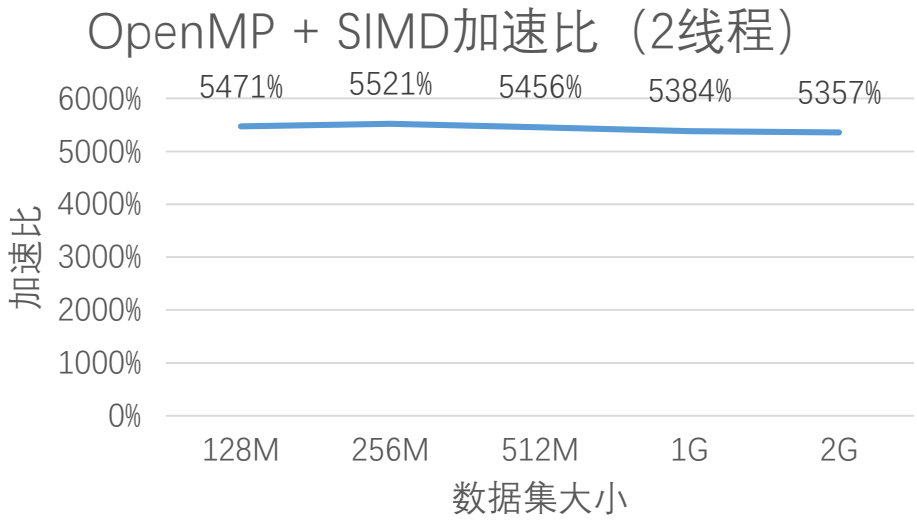

实验结果 多线程

数据集大小	OpenMP	OpenMP + SIMD	线程数
128M	53ms365us (352%)	3ms190us (5891%)	4
256M	108ms310us (342%)	6ms342us (5849%)	4
512M	215ms506us (342%)	12ms764us (5767%)	4
1G	428ms336us (343%)	25ms256us (5822%)	4
2G	853ms742us (344%)	51ms780us (5678%)	4

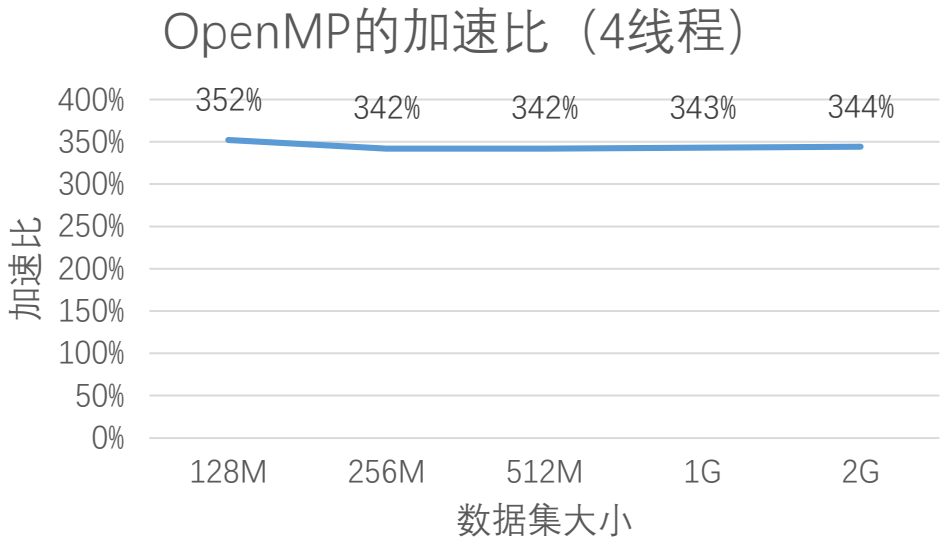

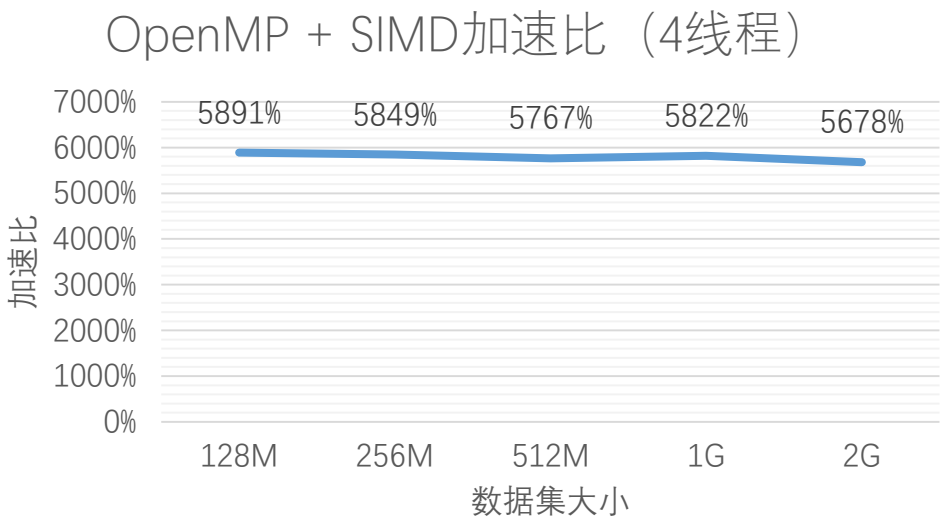

实验结果 多线程

数据集大小	OpenMP	OpenMP + SIMD	线程数
128M	55ms653us (338%)	4ms442us (4231%)	8
256M	93ms683us (396%)	8ms838us (4197%)	8
512M	133ms54us (553%)	17ms476us (4212%)	8
1G	264ms390us (556%)	37ms664us (3904%)	8
2G	551ms360us (533%)	70ms592us (4165%)	8

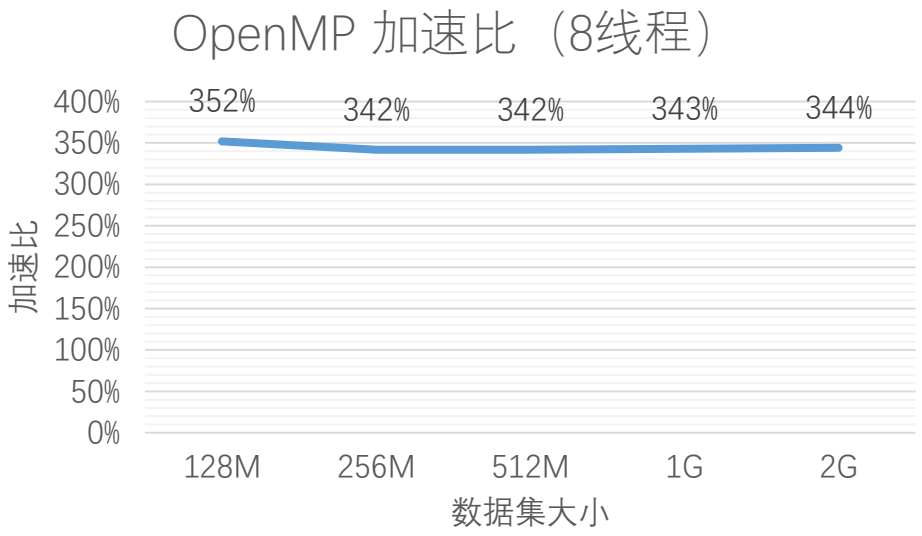

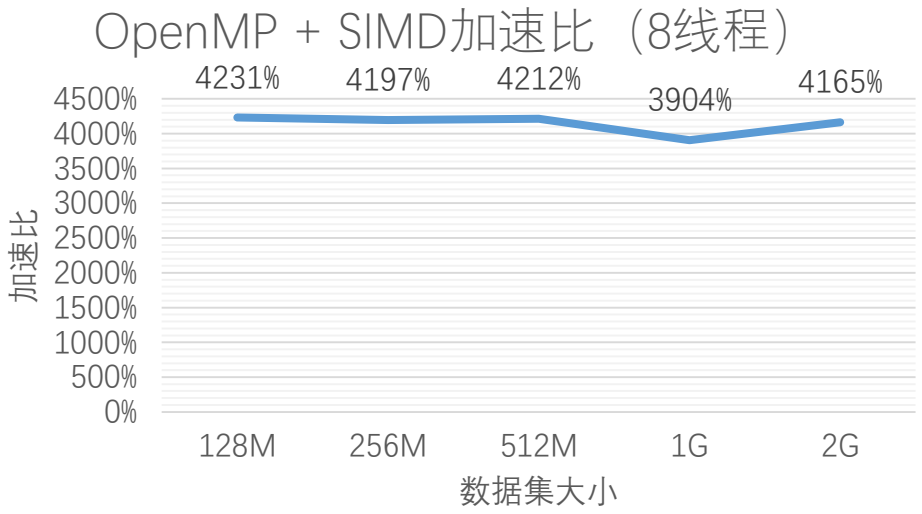

实验结果 多线程

数据集大小	OpenMP	OpenMP + SIMD	线程数
128M	37ms811us (497%)	5ms919us (3175%)	16
256M	71ms498us (519%)	11ms335us (3273%)	16
512M	141ms197us (521%)	23ms207us (3172%)	16
1G	277ms81us (531%)	45ms315us (3245%)	16
2G	550ms498us (534%)	90ms710us (3241%)	16

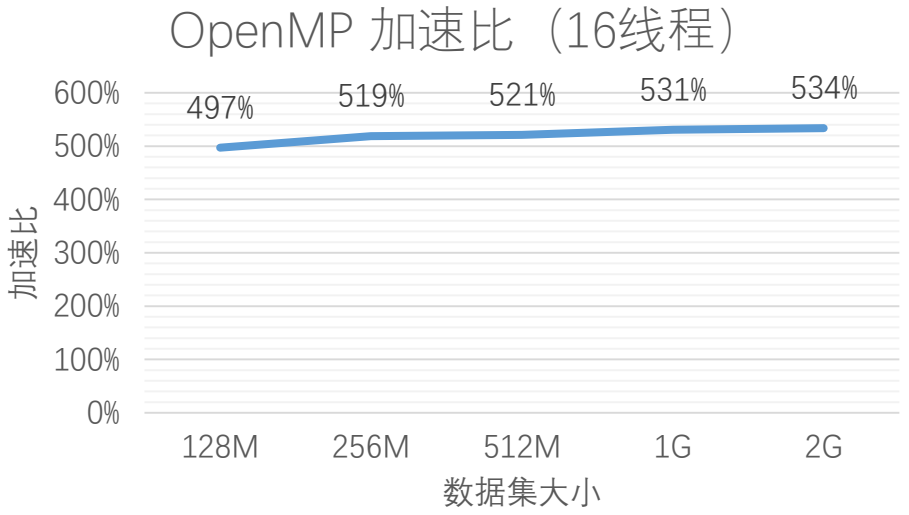

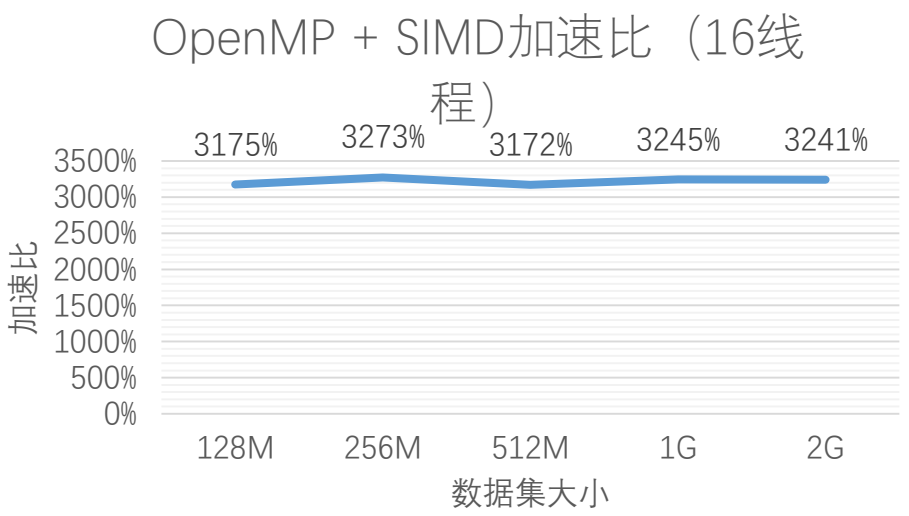

实验结果 不同并行度下的加速效果对比

数据集大小 2G

线程数	KMP	SIMD
1	2s940ms240us (100%)	87ms14us (3379%)
2	853ms742us (344%)	51ms780us (5678%)
4	853ms742us (344%)	51ms780us (5678%)
8	551ms360us (533%)	70ms592us (4165%)
16	550ms498us (534%)	90ms710us (3241%)

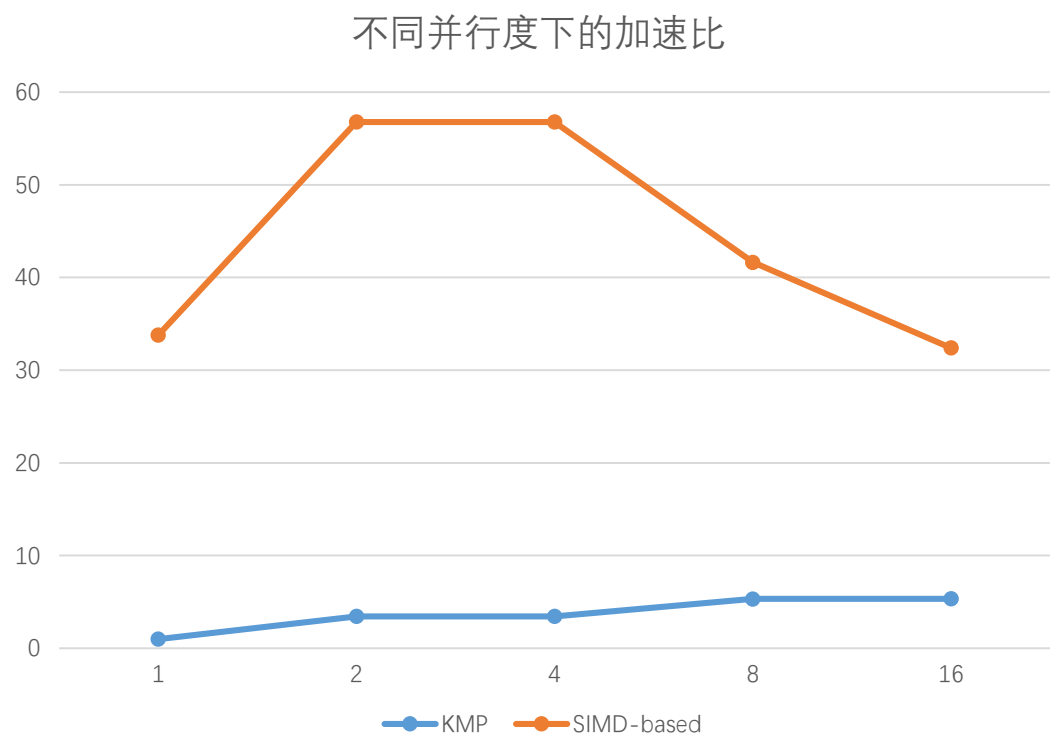

实验分析 不同并行度下的加速效果对比

1. 相比于单线程 KMP 算法，多线程算法性能明显提升；
2. 随着测试数据集的增大，相同线程数的查找算法的时间开销也线性增加。这也印证了我们计算的理论时间复杂度 $O(m/p) => O(m)$；
3. AVX2 是 Intel 在 2013 年提出的一套并行指令集。对于某些场景，我们可以利用硬件提供的新特性、创造新的算法，从而更快地解决问题。结合 SIMD 和 OpenMP 的多线程查找方法，能够明显提升算法性能，充分利用硬件资源；
4. 随着线程数的增加，相同大小测试集的查找时间并没有线性减少，甚至出现了增加。这是由于内存与 CPU 之间的通信是经过总线的，多核 CPU 在访问内存时需要竞争总线资源。当竞争带来的消耗过大时，多线程方法带来的性能收益会下降。